Нейроинформатика. Лабораторная работа 8

Динамические сети

Целью работы является исследование свойств некоторых динамических нейронных сетей, алгоритмов обучения, а также применение сетей в задаче распознавания динамических образов.

```
import numpy as np

import torch
import torch.nn as nn
import torch.optim as optim

import matplotlib.pyplot as plt
from collections import deque
import tqdm
```

Зададим два сигнала - управляющий сигнал ($u(k)$) и выходной ($y(k)$).

```
def u(k):
    return np.sin(k**2 - 2*k + 3)


N = 500 # количество элементов в датасете


t = np.linspace(0, 5, N)

x = u(t) # буду обозначать входные данные через x, так привычнее

y = [0]
for i in range(len(t) - 1):
    y.append(y[-1] / (1 + y[-1]**2) + x[i])

y = np.array(y)
assert x.shape == y.shape

x.shape
```

```
(500,)
```

Сгенерируем датасет для обучения. Разобьем имеющиеся точки на временные ряды

```
def gen_dataset(x, y, delay=5):
    return [(
        np.array(x[i:i+delay], dtype=np.float32),
        np.array(y[i+delay], dtype=np.float32)
     ) for i in range(len(x) - delay)]


train_data = gen_dataset(x, y)
```

Подготовим торчевый дата лоадер

```
data_loader = torch.utils.data.DataLoader(train_data, batch_size=1, shuffle=False)


for i in data_loader:
    print(i[0].shape, i[1].shape)
    break
```

```
torch.Size([1, 5]) torch.Size([1])
```

Для решения этой задачи будем использовать сеть NARX. Для ее реализации нам понадобится вспомогательный слой TDL - Time Delay Layer. Реализуем сначала его. По сути это обертка над очередью, в которой мы придерживаем некоторые элементы на время.

```
class TDL(nn.Module):
    def __init__(self, in_features, delay=1):
        super(TDL, self).__init__()
        self.in_features = in_features
        self.delay = delay
        self.line = deque() # очередь с элементами
        self.clear()
```

```
    def clear(self):
        # очистим текущую очередь и заполним ее нулями
        self.line.clear()
        for i in range(self.delay):
            self.line.append(torch.zeros(self.in_features))

    def push(self, input):
        # добавить элемент в очередь
        self.line.appendleft(input)

    def forward(self, input=None):
        # возвращаем первый добавленный элемент и удаляем его из очереди
        return self.line.pop()
```

Теперь можем реализовать NARX

```
class NARX(nn.Module):
    def __init__(self, in_features, hidden_features, out_features, delay1, delay2):
        super(NARX, self).__init__()

        self.in_features = in_features
        self.hidden_features = hidden_features
        self.out_features = out_features

        self.line1 = TDL(in_features, delay1)
        self.line2 = TDL(out_features, delay2)

        self.w1 = torch.nn.Parameter(torch.randn(in_features, hidden_features))
        self.w2 = torch.nn.Parameter(torch.randn(hidden_features, out_features))
        self.w3 = torch.nn.Parameter(torch.randn(out_features, hidden_features))

        self.b1 = torch.nn.Parameter(torch.randn(hidden_features))
        self.b2 = torch.nn.Parameter(torch.randn(out_features))

    def clear(self):
        self.line1.clear()
        self.line2.clear()

    def forward(self, input):
        res = torch.tanh(
            self.line1() @ self.w1 + self.line2() @ self.w3 + self.b1
        ) @ self.w2 + self.b2
        self.line1.push(input.clone().detach()) # сохранять будем копии
        self.line2.push(res.clone().detach())
        return res
```

Обучаем модель

```
model = NARX(5, 10, 1, 3, 3)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.MSELoss()
epochs = 40
```

```
loss = []
model.train()
for epoch in tqdm.tqdm(range(epochs)):
    epoch_loss = []
    for X_batch, y_batch in data_loader:
        y_pred = model(X_batch)
        cur_loss = criterion(y_batch, y_pred)
        epoch_loss.append(cur_loss.item())
        cur_loss.backward()

        optimizer.step()
        optimizer.zero_grad()
    loss += [np.mean(epoch_loss)]
```

```
  0%|          | 0/40 [00:00<?, ?it/s]/usr/local/lib/python3.8/dist-packages/torch/nn/modules/loss.py:536: UserWarning: Using a tar
  return F.mse_loss(input, target, reduction=self.reduction)
100%|██████████| 40/40 [00:25<00:00,  1.55it/s]
```

Посмотрим на график лосса

```
plt.figure(figsize=(15, 8))
```

```
plt.xlabel('epoch')
plt.ylabel('MSE')
plt.plot(range(1, epochs+1), loss)
plt.title('Loss')
plt.grid()

plt.show()
```

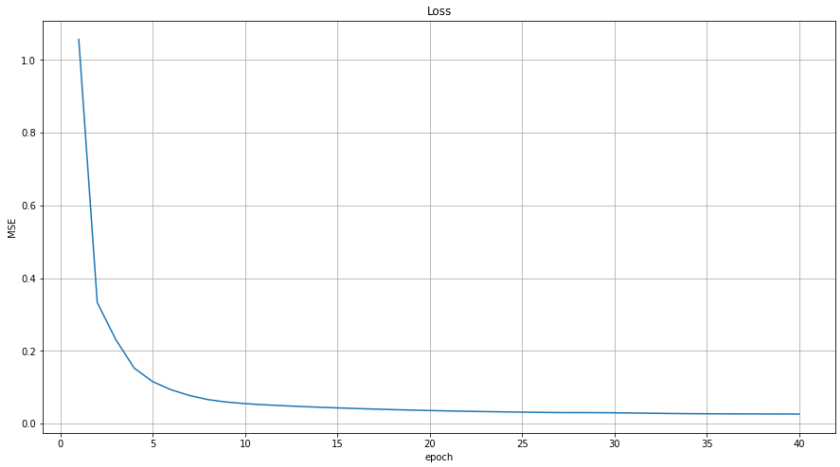


```
print(f'MSE = {loss[-1]}')
```

```
MSE = 0.026033247566106487
```

Лосс падает, модель обучилась.

Проверим работу модели

```
model.eval()
model.clear()

preds = []
for X_batch, _ in data_loader:
    preds.append(model(X_batch).detach().numpy().item(-1))


plt.figure(figsize=(15, 8))

plt.plot(t[5:], y[5:], label='true')
plt.plot(t[5:], preds, label='predicted')
plt.legend()
plt.grid()
plt.show()
```

Модель смогла достаточно точно приблизить искомый сигнал. Но правда наблюдается некая "зубчатость" предсказанного ответа на границах и на закруглениях кривой. Интересно, что с увеличением числа эпох количество таких зубцов только увеличивается

Вывод

В данной лабораторной работе я познакомился с сетью NARX и попробовал применить ее для задачи предсказания сигнала. Сеть имеет довольно сложную архитектуру, при этом она довольно хорошо справилась с поставленной задачей.

Получили MSE = 0.026